



klicken






GLIEDERUNG


- Intuition
- Algorithmus
- Eigenschaften
- Anwendungen

INTUITION



Funktion bekannt

INTUITION



Funktion unbekannt

ALGORITHMUS

Gegeben: $f : \Omega \mapsto \mathbb{R}^+$, Vorschläge $G(x_{k+1}|x_k)$, Startpunkt x_0

1. Ziehe Vorschlag $x' \sim G(x'|x_k)$

2. Akzeptanzwahrscheinlichkeit $\alpha = \frac{f(x')}{f(x_k)} \cdot \underbrace{\frac{G(x_k|x')}{G(x'|x_k)}}_{\text{Hastings Term}}$

3. Entscheide zufällig: $u \sim \mathcal{U}(0, 1)$

- $u \leq \alpha$: $x_{k+1} = x'$ (Akzeptanz)
- ansonsten: $x_{k+1} = x_k$ (Ablehnung)

ALGORITHMUS

Gegeben: $f : \Omega \mapsto \mathbb{R}^+$, Vorschläge $G(x_{k+1}|x_k)$, Startpunkt x_0

1. Ziehe Vorschlag $x' \sim G(x'|x_k)$

2. Akzeptanzwahrscheinlichkeit $\alpha = \frac{f(x')}{f(x_k)} \cdot \underbrace{\frac{G(x_k|x')}{G(x'|x_k)}}_{\text{Hastings Term}}$

3. Entscheide zufällig: $u \sim \mathcal{U}(0, 1)$

- $u \leq \alpha$: $x_{k+1} = x'$ (Akzeptanz)
- ansonsten: $x_{k+1} = x_k$ (Ablehnung)

ALGORITHMUS

Gegeben: $f : \Omega \mapsto \mathbb{R}^+$, Vorschläge $G(x_{k+1}|x_k)$, Startpunkt x_0

1. Ziehe Vorschlag $x' \sim G(x'|x_k)$

2. Akzeptanzwahrscheinlichkeit $\alpha = \frac{f(x')}{f(x_k)} \cdot \underbrace{\frac{G(x_k|x')}{G(x'|x_k)}}_{\text{Hastings Term}}$

3. Entscheide zufällig: $u \sim \mathcal{U}(0, 1)$

- $u \leq \alpha$: $x_{k+1} = x'$ (Akzeptanz)
- ansonsten: $x_{k+1} = x_k$ (Ablehnung)

EIGENSCHAFTEN

EIGENSCHAFTEN

- $\{x_k\}$ bilden eine *Markovkette*
- Kette "vergisst", nur x_k bestimmt x_{k+1}
- stationäre Verteilung $x \sim \pi(x)$
- gewollt: $\pi(x) \stackrel{!}{=} \frac{f(x)}{\int f(x)}$

KORREKTHEIT

Metropolis-Hastings konvergiert gegen korrektes $\pi(x)$ wenn:

1. π ist *invariant* • wenn $x_k \sim \pi$ dann $x_{k+1} \sim \pi$
2. G ist *ergodisch* • jeder mögliche Zustand wird erreicht
3. G ist *aperiodisch* • von x nach y in beliebiger Schrittzahl



[Šik & Jaroslav 2018]

GLEICHGEWICHT

- per Konstruktion $\pi(x)\mathbb{P}(x|y) = \pi(y)\mathbb{P}(y|x)$
 - *detailed balance*, Equilibrium
 - Hastings-Term $\frac{G(x'|x_k)}{G(x_k|x')}$ für asymmetrische G
 - MH optimal unter balancierten Ketten
- $\xrightarrow{SC} \pi(x)$ ist invariante Verteilung zu $\mathbb{P}$
- aber ist $\pi(x)$ die korrekte Verteilung?

[Chib & Greenberg 1995]

ERGODIZITÄT



zeichnen, M drücken

Standardabweichung ($e-3$)

10



P globale Mutation ($e-6$)

0



ERGODIZITÄT

- Ergodisch (Irreduzibel)
 - $\forall x : f(y) > 0 \implies \exists k < \infty : \mathbb{P}(x_k \in dy | x) > 0$
 - *"zu jedem möglichen y in endlich vielen Schritten"*
 - *" π unabhängig von Startzustand"*
- Globale Mutation löst dieses Problem, jedes y möglich

APERIODIZITÄT

Aperiodisch

- $\nexists k > 1 : \forall a, b, x_a \rightarrow^* x_b : b - a \bmod k = 0$
- $\Leftarrow$ Selbstübergang + Balance

WIE WÄHLT MAN G?


- $G(y | x) = G_1(x - y)$
 - *Random Walk*
 - $y = x + z$ mit "Rauschen" z
 - z.B. $z \sim \mathcal{N}$
- $G(y | x) = G_2(y)$
 - *Independence Chain*
 - z.B. Importance Sampling von f

WIE WÄHLT MAN G?

- zu wenig Varianz:
 - unwahrscheinliche Gebiete unterrepräsentiert
 - Domäne wird langsam durchsucht
- zu hohe Varianz:
 - lokale Information wird nicht genutzt
- optimale Akzeptanzraten χ problemabhängig

$$(\chi_1 = 0.44, \quad \chi_\infty = 0.234)$$

WIE WÄHLT MAN G?



Standardabweichung ($e-2$)

1

P globale Mutation ($e-2$)

0

Sample Anzahl (1000)

klicken

Akzeptanz 93.6%

Genauigkeit 43.7%

VOR- UND NACHTEILE

VORTEILE

- Nur punktweise Auswertung von f nötig
- Kein Vorwissen über f , keine Kontinuität
- nutzt lokale Informationen (!)
- effizienter in höheren Dimensionen

NACHTEILE

- $\{x_k\}$ sind korreliert (χ niedrig?)
- transiente Phase praktisch nutzlos
- Konvergenzdauer unklar
- Anfangsphase ungenau, wenn nicht $x_0 \sim \pi$
 - *"start-up bias" oder "burn-in period"*
 - $\Rightarrow$ Bootstrapping

[Šik & Jaroslav 2018] [Kelemen 2002]

ANWENDUNG

METROPOLIS LIGHT TRANSPORT

PSSMILT

- Idee: Pathtracer ist Funktion $L(\vec{\mathbf{x}}, x_c, y_c) : [0; 1]^n \mapsto \mathbb{R}^+$
- Primary Sample Space: Zufallsvektor $\vec{\mathbf{x}} \in [0; 1]^n$
- Strahldichte an Stelle x_c, y_c ist $\int_{[0;1]^n} L(\vec{\mathbf{x}}, x_c, y_c) d\vec{\mathbf{x}}$
- Monte Carlo Summe: $\frac{1}{N} \sum_{k=1}^N \frac{f(x_k)}{p(x_k)} \xrightarrow{N \rightarrow \infty} \int f(x) dx$
- *Metropolis Sampling* für *Importance Sampling* von $\vec{\mathbf{x}}_k$

[Kelemen 2002]



PSSMILT

nutze seltene, lichttragende Pfade voll aus




[Bitterli 2016]

PSSMLT BEISPIEL



Primary Sample Space



Strahlendichte

PSSMILT

Trick: Markov-Kette über Bildfläche $x_c = \vec{\mathbf{x}}_{k,1}$ $y_c = \vec{\mathbf{x}}_{k,2}$

$$I_{x,y} = \int_{\Omega} h(\vec{\mathbf{x}}) L(\vec{\mathbf{x}}) d\Omega \approx \frac{1}{N} \sum_{k=1}^N \frac{h(\vec{\mathbf{x}}_k) L(\vec{\mathbf{x}}_k)}{p(\vec{\mathbf{x}}_k)}$$

Metropolis Sampling mit $p(\vec{\mathbf{x}}) \approx \frac{L(\vec{\mathbf{x}})}{\int_{\Omega} L(\vec{\mathbf{x}})}$

$$\Rightarrow I_{x,y} \approx \underbrace{\frac{1}{N} \sum_{k=1}^N h(\vec{\mathbf{x}}_k)}_{\text{wo landen Samples?}} \cdot \underbrace{\left(\int_{\Omega} L(\vec{\mathbf{x}}) \right)}_{\text{Gesamthelligkeit}}$$

ZUSAMMENFASSUNG

- MH-Algorithmus zieht aus unbekanntem $\pi \propto f$ mit Markov-Kette
- Kaum Voraussetzungen an $f : \Omega \rightarrow \mathbb{R}^+$
- Konvergenz für ergodische, aperiodische (und invariante) Ketten
- Effizienz stark von Vorschlagsverteilung G abhängig
- Nutzen für Importance-Sampling
- PSSMLT nutzt lokale Nachbarschaft für schwierige Pfade

**VIELEN DANK FÜR IHRE
AUFMERKSAMKEIT!**

QUELLEN

- [Kelemen 2002] "A Simple and Robust Mutation Strategy for the Metropolis Light Transport Algorithm", Kelemen et al., in EUROGRAPHICS 2002
- [Chib & Greenberg 1995] "Understanding the Metropolis-Hastings Algorithm", Siddhartha Chib and Edward Greenberg, in The American Statistician Vol. 49 1995
- [Agrawal et al. 2023] "Optimal Scaling of MCMC Beyond Metropolis", Agrawal et. al, in Advances in Applied Probability. 2023;
- [Pharr, Jakob, Humphreys 2021] "Physically Based Rendering: From Theory To Implementation", Matt Pharr, Wenzel Jakob, and Greg Humphreys, ISBN 978-0-12-375079-2
- [Šik & Jaroslav 2018] "Survey of Markov Chain Monte Carlo Methods in Light Transport Simulation", Martin Šik und Jaroslav Krivanek, in IEEE Transactions on Visualization and Computer Graphics
- [Bitterli 2016] Website: Rendering Resources CCO, Benedikt Bitterli, (benedikt-bitterli.me/resources)